

ALMA MATER STUDIORUM · UNIVERSITÀ DI BOLOGNA

---

Scuola di Scienze  
Dipartimento di Fisica e Astronomia  
Corso di Laurea in Fisica

## TITOLO TESI

**Relatore:**

**Prof./Dott. Enrico Giampieri**

**Presentata da:**

**Mattia Ceccarelli**

**Correlatore: (eventuale)**

**Prof./Dott. Nome Cognome**

Anno Accademico 2017/2018

# Indice

<b>1</b>	<b>Introduzione</b>	<b>2</b>
1.1	Algoritmi Genetici . . . . .	2
1.1.1	Operatori . . . . .	2
1.1.2	Struttura di un Algoritmo Genetico . . . . .	3
1.1.3	Applicazioni . . . . .	3
1.2	Reti Neurali . . . . .	3
1.2.1	Il perceptron . . . . .	4
1.2.2	Struttura <i>fully connected</i> . . . . .	5
1.2.3	Evoluzione di una Rete Neurale . . . . .	6
<b>2</b>	<b>Metodologia</b>	<b>7</b>
<b>3</b>	<b>Risultati</b>	<b>8</b>
<b>4</b>	<b>Conclusioni</b>	<b>9</b>
	<b>Bibliografia</b>	<b>10</b>

# Capitolo 1

## Introduzione

In questo capitolo si introdurranno i principali mezzi utilizzati nello svolgimento del progetto di tesi, ossia Algoritmi Genetici per la ricerca di minimi per una funzione ???????? e Reti Neurali fully connected, che svolgono il ruolo di funzione a molti parametri da ottimizzare in un problema di classificazione.

### 1.1 Algoritmi Genetici

Gli algoritmi genetici sono software di ricerca ispirati dalla selezione naturale applicata ad una popolazione di individui, chiamati soluzioni, caratterizzati da un *cromosoma*, spesso rappresentato da una lista di numeri binari o da una stringa. Il parametro che differenzia soluzioni migliori o peggiori è il *fitness*, misurato attraverso la *funzione di fitness* la quale dipende dal problema. L'evoluzione della popolazione avviene attraverso la selezione dei migliori individui che passeranno il loro *cromosoma* alla generazione successiva.

#### 1.1.1 Operatori

Mitchell [1999] I principali operatori che compongono un semplice algoritmo genetico sono:

**Selezione** Questo operatore seleziona i migliori individui, più è alto è il fitness e più è probabile che un individuo venga scelto per creare la nuova generazione

**Crossover** L'operatore di Crossover produce un taglio nel genoma degli individui "genitori" per formare due individui "figli": per esempio prendendo le due stringhe 111000 e 000111, producendo un taglio alla terza posizione otterremo le stringhe 111111 e 000000.

**Mutazione** L'operatore di mutazione si occupa di cambiare casualmente uno o più caratteri di individui scelti a caso nella popolazione.

Il funzionamento di un tipico algoritmo genetico, come descritto da Mitchell [1999] una volta definito il problema, procede in questo modo:

### 1.1.2 Struttura di un Algoritmo Genetico

1. Creazione casuale di  $n$  elementi, che rappresentano la prima popolazione.
2. Calcolo del fitness  $f(x)$  di ogni soluzione  $x$  della popolazione.
3. Fino a che non sono stati generati  $n$  discendenti ripetere:
  - a. Selezione di due genitori dalla popolazione dove un individuo può anche essere scelto più volte.
  - b. Con probabilità  $p_c$  (probabilità di crossover) applicare l'operatore di crossover sui due genitori. Nel caso non avvenisse alcun crossover, copiare i genitori.
  - c. Con probabilità  $p_m$  (probabilità di mutazione) applicare l'operatore di mutazione sui figli.
4. Sostituire la vecchia popolazione con la nuova generazione e ripetere dal secondo passaggio.

Ogni iterazione di questo processo è chiamata *generazione*.

### 1.1.3 Applicazioni

Il classico esempio di utilizzo di un algoritmo genetico è la ricerca dei massimi di una funzione. In tal caso, un individuo è rappresentato da una stringa di bit, la *funzione di fitness* è la funzione stessa e il *fitness* delle soluzioni è il valore della funzione calcolato nel punto di cui l'individuo è la rappresentazione binaria. Oltre ad essere l'esempio più semplice risulta anche quello più significativo: di fatto lo scopo di un algoritmo genetico è ottimizzare.

Da migliorare

## 1.2 Reti Neurali

Una rete neurale è una struttura interconnessa di semplici unità procedurali, chiamate nodi. La loro funzionalità si ispira ai neuroni del regno animale. La capacità di elaborazione della rete neurale è contenuta nella “forza” delle connessioni tra nodi, espressa dai *pesi* dei collegamenti, ottenuti da processi di *addestramento* o *apprendimento*. Gurney [1997]

### 1.2.1 Il perceptron

Nielsen [2015] Il perceptron è stato sviluppato negli anni '50 e '60 dal ricercatore Frank Rosenblatt ispirandosi ai lavori antecedenti di Warren McCulloch e Walter Pitts. È l'unità di base di una rete neurale e il suo funzionamento è il seguente: il perceptron riceve  $n$  valori in ingresso  $x_1, x_2, \dots, x_n$  e restituisce 1 o 0 a seconda che la somma pesata degli input superi o no un valore di soglia, con pesi  $w_1, w_2, \dots, w_n$ . Ad esempio nel perceptron mostrato in figura 1.1:




Figura 1.1: *Perceptron con 3 input ed un output*

l'output sarà determinato da:

$$\begin{cases} 0 & \text{se } \sum_i x_i w_i \leq \text{valore di soglia} \\ 1 & \text{se } \sum_i x_i w_i > \text{valore di soglia} \end{cases}$$

anche se è più comune trovare la scrittura:

$$\begin{cases} 0 & \text{se } \sum_i x_i w_i + b \leq 0 \\ 1 & \text{se } \sum_i x_i w_i + b > 0 \end{cases}$$

dove  $b$  è detto *bias* del perceptron. È attraverso *pesi* e *bias* che il perceptron può soppesare diverse prove e compiere decisioni.

Tuttavia se la rete contenesse perceptron, anche un piccolo cambiamento nei parametri interni potrebbe causare un cambiamento netto nel comportamento della rete [Nielsen [2015]], per questo è preferibile utilizzare una *funzione di attivazione* che rende continuo l'output di un nodo. Un esempio di funzione di attivazione è la sigmoide definita come:

$$\sigma(z) = \frac{1}{1 + e^{-z}} \quad (1.1)$$

e l'output di un nodo della rete diventa :

$$y = \sigma\left(\sum_i x_i w_i + b\right) \quad (1.2)$$

risultato che è continuo e compreso tra zero ed uno.

Un altro tipo di funzione di attivazione è la *Rectified Linear Units* o *ReLU* e si presenta come:

$$y(x) = \max\{0, x\} \quad (1.3)$$




Figura 1.2: confronto tra due funzioni di attivazione: a sinistra sigmoideale e a destra *ReLU*

La scelta della migliore funzione di attivazione non è univoca e dipende dal problema che viene affrontato.

### 1.2.2 Struttura *fully connected*

La struttura di una rete neurale *fully connected* composta da molti *layer* di neuroni è come quella mostrata in figura 1.3:




Figura 1.3: Esempio di rete neurale *fully connected* in cui viene mostrata la distinzione tra *input layer*, *hidden layer* e *output layer*

In una rete come questa ad ogni collegamento è associato un peso e ad ogni nodo è associato un *bias*: gli output dei *neuroni* del *layer* di input diventano a loro volta valori in ingresso del *layer* successivo in un procedimento a catena fino all'ultimo *layer*, che restituisce la risposta della rete. L'addestramento della rete consiste nel valutarne gli output in un determinato set di dati, chiamato *training dataset*, confrontarli con i valori attesi, forniti dallo stesso *dataset*, e modificare pesi e *bias* in modo che la risposta si avvicini a ciò che ci si aspetta.

Da completare con algoritmo di BackPropagation???

### 1.2.3 Evoluzione di una Rete Neurale

## Capitolo 2

### Metodologia



## Capitolo 3

### Risultati

Capitolo 4

Conclusioni

# Elenco delle figure

1.1	<i>Perceptron con 3 input ed un output</i>	4
1.2	<i>confronto tra due funzioni di attivazione: a sinistra sigmoideale e a destra ReLU</i>	5
1.3	<i>Esempio di rete neurale fully connected in cui viene mostrata la distinzione tra input layer, hidden layer e output layer</i>	5

# Bibliografia

- Kevin Gurney. *An Introduction to Neural Networks*. UCL Press, 1997. ISBN 0-203-45151-1.
- J. D. Hunter. Matplotlib: A 2d graphics environment. *Computing In Science & Engineering*, 9(3):90–95, 2007. doi: 10.1109/MCSE.2007.55.
- Melanie Mitchell. *An Introduction to genetic algorithm*. The MIT Press, 1999. ISBN 0262133164.
- Michael A. Nielsen. *Neural Network and Deep Learning*. Determination Press, 2015.
- F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel, M. Blondel, P. Prettenhofer, R. Weiss, V. Dubourg, J. Vanderplas, A. Passos, D. Cournapeau, M. Brucher, M. Perrot, and E. Duchesnay. Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12:2825–2830, 2011.